

DAY 3 • WORKSHOP

Advanced Data Engineering & Applied Analytics

Loan Analytics Pipeline

CSV → Python ETL → MSSQL → Power BI



โครงวันนี้ — 1 วัน (6 ชม.)

AGENDA

เช้า (3 ชม.)

ETL → MSSQL Star Schema

- สำรองข้อมูล + ออกแบบ star schema
- ETL: clean → validate → transform
- สร้าง dimensions + fact
- โหลดเข้า MSSQL (de_loan_dw)

บ่าย (3 ชม.)

Power BI Dashboard

- ต่อ Power BI → MSSQL
- สร้าง model (star) + relationships
- DAX measures: Default Rate %, ROI %
- Dashboard: Analytics + Data Quality

โจทย์: Lending Club Loan Data

บริษัท

Lending Club = แพลตฟอร์มสินเชื่อส่วนบุคคล (P2P) รายใหญ่ของสหรัฐฯ
เปิดข้อมูลสินเชื่อย้อนหลังจริง — แต่ละแถว = 1 สินเชื่อ (วงเงิน · ดอกเบี้ย · เกรด A-G · สถานะ)

เราใช้จำลองงาน DE จริง: เปลี่ยน ข้อมูลดิบ → ตอบคำถามธุรกิจ ได้

คำถามธุรกิจที่ dashboard จะตอบ:

🔴 เกรดไหน **เบี้ยวหนี้สูง** เมื่อเทียบกับดอกเบี้ยที่คิด? → ตั้งราคาถูกไหม

💰 สินเชื่อกลุ่มไหน **กำไร/ขาดทุน?**

📈 แนวโน้ม **ยอดปล่อยกู้ + อัตราเบี้ยวหนี้** เป็นยังไง?

ข้อมูลตัวอย่าง

loan_sample.csv

~50,000

แถว × ~25 คอลัมน์


ตัวอย่างคอลัมน์ที่ต้องล้าง:

int_rate "13.56%" · term "36 months"

ภาพรวม: จากไฟล์ดิบ → dashboard

ARCHITECTURE

ทุกอย่างรันบน JupyterHub → โหลดเข้า MSSQL (sql1) → Power BI ต่อผ่าน host



💡 โค้ด ETL = แพ็กเกจ **loan_etl** — ชัดเดียวใช้ได้ทั้ง notebook / CLI / API

ETL = Extract ดึงข้อมูลออกมา → **Transform** แปลง/ล้าง → **Load** โหลดเข้าปลายทาง



MORNING SESSION

เช้า — ETL → MSSQL Star Schema

จาก CSV ดิบ → ข้อมูลสะอาดใน data warehouse

เครื่องมือ + Setup

เข้า · ขั้นตอนเตรียม



JupyterHub

รัน notebook ทำ ETL บน browser
— ไม่ต้องติดตั้งอะไรในเครื่อง



loan_etl

แพ็คเกจ ETL พร้อมใช้ — clean /
validate / transform / load



nbgitpuller

คลิกลิงก์เดียว ดึง repo + notebook
มาไว้บน hub



เข้าใช้ JupyterHub — ทุกคนใช้บัญชีกลางนี้

URL jupyter-hub.minddatatech.com user deadadmin pass deadadmin@2026



ดึง repo เข้า hub

สำรวจข้อมูล — ของจริงไม่เคยสะอาด

Notebook 01

คอลัมน์เก็บมาเป็น “ข้อความปนสัญลักษณ์” — คำนวณไม่ได้ทันที:

คอลัมน์	ดิบ (ข้อความ)	หลังแก้
int_rate	"13.56%"	13.56 (ตัวเลข)
term	" 36 months"	36
emp_length	"10+ years"	10
issue_d	"Dec-2018"	วันที่จริง

เป้าหมาย

ป้อนข้อมูลให้เป็น **Star Schema**

- 1 fact (fact_loan)
- 7 dimensions (date, grade, purpose, status, geo, ...)

ตั้งสภาพแวดล้อม + สำรองข้อมูลจริง

 20 นาที

 คลิกเดียว — เปิด hub + ดึง repo อัตโนมัติ

 GitHub repo

- 1 login ด้วยบัญชีกลาง (กล่องขวา →)
- 2 กดปุ่มเขียวด้านบน — ดึง repo อัตโนมัติ
- 3 รัน 00_setup — ตั้ง TEAM_ID ของทีม
- 4 รัน 01_explore — ดูข้อมูลดิบที่ต้องล้าง

 บัญชีกลาง — ใช้ร่วมกัน

URL	jupyter-hub.minddatatech.com
user	deadmin
pass	deadmin@2026

 **เสร็จแล้วได้:** repo อยู่บน hub · เห็นปัญหาในข้อมูล · พร้อมลงมือ ETL

Data Model — ทำไมต้อง Star Schema?

เข้า · ออกแบบก่อนทำ

ก่อนเขียน ETL ออกแบบ “**ปลายทาง**” ก่อน — ข้อมูลควรอยู่รูปไหนถึงตอบคำถามธุรกิจได้ง่ายที่สุด

fact (ตารางกลาง)

เก็บ “ตัวเลขวัดผล” — วงเงิน · ดอกเบี้ย
is_default · profit
1 แถว = 1 สินเชื่อ + คีย์ไปหา dim

dimension (ตารางรอบ)


เก็บ “มุมมอง” — เกรด · วันที่ · รัฐ
วัตถุประสงค์
ใช้ filter / group เวลาวิเคราะห์

ทำไม star schema?

- ตอบคำถามแบบ “**X ต่อ Y**” ได้ทันที — default rate ต่อเกรด · กำไรต่อวัตถุประสงค์
- Power BI ทำงานกับ star schema ได้เร็ว + relationship เข้าใจง่าย

Star Schema — fact + 7 dimensions

เข้า · Data Model



Grain = “1 แถวของ fact แทนอะไร” → ที่นี้ = 1 สินเชื่อ · กำหนดให้ชัดเป็นขั้นแรกของการออกแบบ schema

ETL ① Clean — แก้ format ให้คำนวณได้

Notebook 02

เปลี่ยนข้อความปนสัญลักษณ์ → ตัวเลข/วันที่จริง

- ลบ % / ตัดคำว่า months / years
- แปลงเป็น numeric / datetime
- ตัดช่องว่าง (strip) ข้อความ

```
# int_rate "13.56%" -> 13.56
df['int_rate'] = pd.to_numeric(
    df['int_rate'].str
    .replace('%','').str.strip())

# term " 36 months" -> 36
df['term_months'] = (df['term']
    .str.extract(r'(\d+)'))

# issue_d "Dec-2018" -> datetime
df['issue_date'] = pd.to_datetime(
    df['issue_d'], format='%b-%Y')
```

ETL ② Validate + Quarantine

Notebook 02

ตรวจ **ทุกแถว** ตามกฎ business — แถวไม่ผ่าน “ไม่ลบ” แต่เก็บใน quarantine พร้อมเหตุผล (audit)

```
# รวมทุกกฎเป็น mask เดียว
mask = ( (df['loan_amnt'] > 0)
        & (df['annual_inc'] >= 0)
        & df['term_months'].isin([36,60])
        & df['loan_status'].isin(VALID) )
```

```
good = df[mask]    # ผ่าน
bad  = df[~mask]   # ไม่ผ่าน
bad['reject_reason'] = why(bad)
```

แต่ละบรรทัดทำอะไร

mask เงื่อนไขทุกข้อรวมด้วย & (AND)

df[mask] เก็บเฉพาะแถวที่ผ่าน → good

df[~mask] แถวไม่ผ่าน (~ = NOT) → bad

reject_reason ใส่เหตุผลที่ถูกลด → audit

ผล: good 482 · quarantine 18 แถว

ETL ③ Transform — สร้างความหมายธุรกิจ

Notebook 02

เพิ่มคอลัมน์ที่ **ธุรกิจใช้จริง** จากข้อมูลที่สะอาดแล้ว — ขั้นนี้คือ ~70% ของงาน DE

```
def derive(df):  
    df['is_default'] = (df['loan_status']  
        .isin(BAD).astype(int))  
    df['fico_avg'] = df[['fico_low',  
        'fico_high']].mean(axis=1)  
    df['profit'] = (df['total_pymnt']  
        - df['funded_amnt'])  
    return df
```

คอลัมน์ที่ได้ (ใช้ทำ KPI)

- **is_default** 1 = เบียดหนี้ → คำนวณ default rate
- **fico_avg** คะแนนเครดิตเฉลี่ย (low+high)/2
- **profit** กำไร = เงินได้คืน - เงินปล่อยกู้
- **status_group** จัดกลุ่มสถานะ Good / Bad

ETL: clean → validate → transform

 30 นาที [GitHub repo](#)

เปิด: [notebooks/02_etl](#)

- 1 รัน clean — แปลง %, term, วันที่ ให้คำนวณได้
- 2 รัน validate — แยก good / quarantine + เหตุผล
- 3 รัน transform — สร้าง is_default · profit · fico_avg
- 4 ตรวจสอบจำนวนแถว good / quarantine ว่าตรงไหม

✓ **เสร็จแล้วได้:** DataFrame สะอาด + คอลัมน์ธุรกิจ พร้อมขึ้น star schema

โหลดเข้า MSSQL — จบ ETL

Notebook 03



Database
de_loan_dw



Login (ร่วมกัน)
deadadmin



ชื่อตาราง
<TEAM_ID>_fact_loan



Reconcile
row + sum ตรงกัน



ทุกคนใช้ deadadmin เหมือนกัน — กันชนด้วย prefix ชื่อตาราง (TEAM_ID) → ไม่ต้องสร้าง schema รายทีม

โหลด Star Schema เข้า MSSQL

 25 นาที [GitHub repo](#)

เปิด: [notebooks/03_star_schema_load](#)

- 1 สร้าง dimensions + fact จากข้อมูลที่ transform แล้ว
- 2 เขียนลง de_loan_dw → ตาราง <TEAM_ID>_*
- 3 รัน reconcile — row count + ยอดรวมต้องตรง
- 4 เปิด Power BI Desktop ค้างไว้ ใช้ต่อช่วงบ่าย

✓ **เสร็จแล้วได้:** fact_loan + 7 dimensions อยู่ใน MSSQL — จบกระบวนการ ETL



AFTERNOON SESSION

บ่าย — Power BI Dashboard

ต่อ MSSQL → สร้าง model + DAX → dashboard เล่าเรื่อง

ติดตั้ง Power BI Desktop (Windows)

บ่าย · เตรียม

ฟรี · ใช้ได้เฉพาะ Windows — เลือกติดตั้งได้ 2 ทาง

1 Microsoft Store

แนะนำ

- เปิด Microsoft Store
- ค้นหา "Power BI Desktop"
- กด Get / Install
- อัปเดตอัตโนมัติ

2 ดาวน์โหลด Installer

- powerbi.microsoft.com/desktop
- Download → ได้ไฟล์ .exe
- รันไฟล์ → Next → Install
- เหมาะกับเครื่องที่ปิด Store



Mac / Linux: ไม่มี Power BI Desktop — ใช้ **Power BI Service (เว็บ)** หรือรันผ่าน Windows VM

Power BI: Connect → Model → DAX

บ่าย

1 Connect

Get Data → SQL Server
34.59.223.196 / de_loan_dw
เลือกตาราง <TEAM_ID>_*

2 Model

เชื่อม relationships
fact → dim (star)
mark dim_date เป็น date table

3 DAX

Default Rate %
ROI %, Total Funded
Avg Int Rate

ตัวอย่าง DAX: $\text{Default Rate \%} = \text{DIVIDE}(\text{SUM}(\text{is_default}), \text{COUNTROWS}(\text{fact_loan})) * 100$

ติดตั้ง Power BI + ต่อ MSSQL

 45 นาที [GitHub repo](#)


เปิด: Power BI Desktop → SQL Server

- 1 ติดตั้ง Power BI Desktop (Store หรือ .exe)
- 2 Get Data → SQL Server → 34.59.223.196 / de_loan_dw
- 3 เลือกตาราง <TEAM_ID>* ของทีมเรา
- 4 Model view: เชื่อม fact → dim + เพิ่ม DAX measures

✓ **เสร็จแล้วได้:** model แบบ star + measures (Default Rate %, ROI %) พร้อมใช้

Loan Analytics Dashboard — Layout

บัญชี · ผลลัพธ์



Data Quality Dashboard — DAX

บ่าย · dq_power-bi

วัดคุณภาพข้อมูลที่ ETL แล้ว 3 มุม — Data Rows · Validity · Completeness

Data Rows

จำนวนแถวทั้งหมด

Validity

% แถวที่ผ่านกฎ (valid)

Completeness

% ช่องที่ไม่ว่าง (not null)

```
TotalRows = COUNTROWS(loan_data)
```

```
ValidRows = CALCULATE(  
    COUNTROWS(loan_data),  
    loan_data[is_valid] = "TRUE")
```

```
Validity % = DIVIDE([ValidRows],  
    [TotalRows]) * 100
```

```
Completeness % = DIVIDE(  
    [NotNullCount], [TotalRows]) * 100
```

DQ Dashboard — Layout & Visuals

บ้าย · dq_power-bi

3 ส่วนตาม dq_power-bi — ใช้ **Card** (ตัวเลขใหญ่) + **Donut** (สัดส่วน TRUE/FALSE/NULL)

Data Rows

Card แสดง TotalRows (เช่น 1.4M แถว)

#9DC3E6

Validity

Donut: TRUE / FALSE / NULL ต่อคอลัมน์

#FFE699

Completeness

Donut: NULL vs NOT NULL ต่อคอลัมน์

#C6E0B4

ต้นแบบเต็ม + ไฟล์ .pbix: github.com/amornpan/dq_power-bi

สร้าง Dashboard เล่าเรื่อง

 60 นาที [GitHub repo](#)

เปิด: Power BI → Report view

- 1 หน้า Analytics: KPI cards + bar / line / map
- 2 หน้า Data Quality: Card + Donut (validity / completeness)
- 3 ใส่ slicer (เกรด · ช่วงเวลา) ให้กดเล่นได้
- 4 ตรวจสอบตัวเลขกับผล reconcile ให้ตรง

✓ **เสร็จแล้วได้:** dashboard 2 หน้า ตอบโจทย์ธุรกิจ + วัดคุณภาพข้อมูลได้

สร้าง pipeline จริง CSV → Power BI



- ✓ เขียน Python ETL: clean / validate / quarantine / transform
- ✓ ออกแบบ star schema → โหลดเข้า MSSQL (de_loan_dw)
- ✓ ต่อ Power BI → สร้าง dashboard (Analytics + Data Quality)

Next steps: dbt · Apache Airflow · Cloud DW (BigQuery/Synapse) · Power BI Advanced · CI/CD

ขอบคุณ — Q & A

 amornpan/advanced-de-applied-analytics



Thank You