

DAY 3 • WORKSHOP

Advanced Data Engineering and Applied Analytics for IT and Developer Teams

Loan Analytics Pipeline

CSV → Python ETL → MSSQL → Power BI





ไ้รรงวันนี — 1 วัน (6 ชม.)

AGENDA



เช้า (3 ชม.)

ETL → MSSQL Star Schema

- สํ้ารวจข้อมูล + ออกแบบ star schema
- ETL: clean → validate → transform
- สร้าง dimensions + fact
- โหลดเข้า MSSQL (de_loan_dw)



บ่าย (3 ชม.)

Power BI Dashboard

- ต่อ Power BI → MSSQL
- สร้าง model (star) + relationships
- DAX measures: Default Rate %, Total Profit
- Dashboard: Loan Analytics



โจทย์: Lending Club Loan Data

Lending Club = แพลตฟอร์มสินเชื่อบุคคล (P2P) รายใหญ่ของสหรัฐฯ

เปิดข้อมูลสินเชื่อย้อนหลังจริง — แต่ละแถว = 1 สินเชื่อ (วงเงิน · ดอกเบี้ย · เกรด A–G · สถานะ)

เราใช้จำลองงาน DE จริง: เปลี่ยน **ข้อมูลดิบ** → **ตอบคำถามธุรกิจ** ได้

คำถามธุรกิจที่ **dashboard** จะตอบ:



เกรดไหน **เบี้ยวหนี้สูง** เมื่อเทียบกับดอกเบี้ยที่คิด? → ตั้งราคาถูกไหม



สินเชื่อกลุ่มไหน **กำไร/ขาดทุน**?



แนวโน้ม **ยอดปล่อยกู้ + อัตราเบี้ยวหนี้** เป็นยังไง?

บริษัท

ข้อมูลตัวอย่าง
loan_sample.csv

5,020

แถว × 22 คอลัมน์

ตัวอย่างคอลัมน์ที่ต้องล้าง:


`int_rate "13.56%" · term " 36 months"`



ภาพรวม: จากไฟล์ดิบ → dashboard

ARCHITECTURE

ทุกอย่างรันบน **JupyterHub** → โหลดเข้า **MSSQL (sql1)** → Power BI ต่อผ่าน host



💡 โค้ด ETL = แพ็กเกจ **loan_etl** — ชุดเดียวใช้ได้ทั้ง notebook / CLI / API

ETL = Extract ดึงข้อมูลออกมา → **Transform** แปลง/ล้าง → **Load** โหลดเข้าปลายทาง



MORNING SESSION

เช้า — ETL → MSSQL Star Schema

จาก CSV ดิบ → ข้อมูลสะอาดใน data warehouse



เครื่องมือ + Setup

เช้า · ชั้นเตรียม



JupyterHub

รัน notebook ทำ ETL บน browser — ไม่
ต้องติดตั้งอะไรในเครื่อง



loan_etl

แพ็คเกจ ETL พร้อมใช้ — clean / validate /
transform / load



github

คลิกลิงก์เดียว ดึง repo + notebook มาไว้บน
hub



❗ **เข้าใช้ JupyterHub** — ทุกคนใช้บัญชีกลางนี้
URL `jupyter-hub.minddatatech.com` user `deadadmin` pass `deadadmin@2026`

▶ [ดึง repo เข้า hub](#)



สำรวจข้อมูล — ของจริงไม่เคยสะอาด

คอลัมน์เก็บมาเป็น “ข้อความปนสัญลักษณ์” — คำนวณไม่ได้ทันที:

Notebook 01

คอลัมน์	ดิบ (ข้อความ)	หลังแก้
int_rate	"13.56%"	13.56 (ตัวเลข)
term	" 36 months"	36
emp_length	"10+ years"	10
issue_d	"Dec-2018"	วันที่จริง



เป้าหมาย

ป้อนข้อมูลให้เป็น **Star Schema**

- 1 fact (fact_loan)
- 7 dimensions (date, grade, purpose, status, geo, ...)



 LAB 1 • ลงมือทำ

 **20 นาที**

ตั้งสภาพแวดล้อม + สำรองข้อมูลจริง

▶ [คลิกเดียว — เปิด hub + ดึง repo อัตโนมัติ](#)

 [GitHub repo](#)

- 1 login ด้วยบัญชีกลาง (กล่องขวา →)
- 2 กดปุ่มเขียวด้านบน — ดึง repo อัตโนมัติ
- 3 รัน 00_setup — ตั้ง TEAM_ID ของทีม
- 4 รัน 01_explore — ดูข้อมูลดิบที่ต้องล้าง

 บัญชีกลาง — ใช้ร่วมกัน

URL	jupyter-hub.minddatatech.com
user	deadmin
pass	deadmin@2026

 **เสร็จแล้วได้:** repo อยู่บน hub • เห็นปัญหาในข้อมูล • พร้อมลงมือ ETL



Data Model — ทำไมต้อง Star Schema?

เช้า • ออกแบบก่อนทำ

ก่อนเขียน ETL ออกแบบ “ปลายทาง” ก่อน — ข้อมูลควรอยู่รูปไหนถึงตอบคำถามธุรกิจได้ง่ายที่สุด

fact (ตารางกลาง)

เก็บ “ตัวเลขวัดผล” — วงเงิน · ดอกเบี้ย
is_default · profit
1 แถว = 1 สินเชื่อ + คีย์ไปหา dim

dimension (ตารางรอบ)

เก็บ “มุมมอง” — เกรด · วันที่ · รัฐ
วัตถุประสงค์
ใช้ filter / group เวลาวิเคราะห์


ทำไม star schema?

- ตอบคำถามแบบ “X ต่อ Y” ได้ทันที — default rate ต่อเกรด · กำไรต่อวัตถุประสงค์
- Power BI ทำงานกับ star schema ได้เร็ว + relationship เข้าใจง่าย



Star Schema — fact + 7 dimensions

เข้า · Data Model



Grain = “1 แถวของ fact แทนอะไร” → ที่นี้ = 1 สินเชื่อ · กำหนดให้ชัดเป็นขั้นแรกของการออกแบบ schema



ETL ① Clean — แก้ format ให้คำนวณได้

Notebook 02

เปลี่ยนข้อความปนสัญลักษณ์ → ตัวเลข/วันที่จริง

- ลบ % / ตัดคำว่า months / years
- แปลงเป็น numeric / datetime
- ตัดช่องว่าง (strip) ข้อความ

```
# int_rate "13.56%" -> 13.56
df['int_rate'] = pd.to_numeric(
    df['int_rate'].str
    .replace('%', '').str.strip())

# term " 36 months" -> 36
df['term_months'] = (df['term']
    .str.extract(r'(\d+)'))

# issue_d "Dec-2018" -> datetime
df['issue_date'] = pd.to_datetime(
    df['issue_d'], format='%b-%Y')
```




ETL ② Validate + Quarantine

Notebook 02

ตรวจ **ทุกแถว** ตามกฎ business — แถวไม่ผ่าน “ไม่ลบ” แต่เก็บใน quarantine พร้อมเหตุผล (audit)

```
# รวมทุกกฎเป็น mask เดียว
mask = ( (df['loan_amnt'] > 0)
        & (df['funded_amnt'] > 0)
        & (df['annual_inc'] >= 0)
        & df['term_months'].isin([36,60])
        & df['loan_status'].isin(VALID) )
good = df[mask]          # ผ่าน
bad  = df[~mask]         # ไม่ผ่าน
bad['reject_reason'] = why(bad)
```

แต่ละบรรทัดทำอะไร

mask เงื่อนไขทุกข้อรวมด้วย & (AND)

df[mask] เก็บเฉพาะแถวที่ผ่าน → good

df[~mask] แถวไม่ผ่าน (~ = NOT) → bad

reject_reason ใส่เหตุผลที่ถูกคัด → audit

ผล: good 5,000 · quarantine 20 แถว



ETL ③ Transform — สร้างความหมายธุรกิจ

Notebook 02

เพิ่มคอลัมน์ที่ **ธุรกิจใช้จริง** จากข้อมูลที่สะอาดแล้ว — ขั้นนี้คือ ~70% ของงาน DE

```
def derive(df):  
    df['is_default'] = (df['loan_status']  
                        .isin(BAD).astype(int))  
    df['fico_avg'] = df[['fico_range_low',  
                        'fico_range_high']].mean(axis=1)  
    df['profit'] = (df['total_pymnt']  
                   - df['funded_amnt'])  
    return df
```

คอลัมน์ที่ได้ (ใช้ทำ KPI)

- **is_default** 1 = เบียดหนี้ → คำนวณ default rate
- **fico_avg** คะแนนเครดิตเฉลี่ย (low+high)/2
- **profit** กำไร = เงินได้คืน - เงินปล่อยกู้
- **status_group** จัดกลุ่มสถานะ Good / Bad



LAB 2 • ลงมือทำ



30 นาที

ETL: clean → validate → transform

เปิด: [notebooks/02_etl](#)



[GitHub repo](#)

- 1 รัน clean — แปลง %, term, วันที่ ให้คำนวณได้
- 2 รัน validate — แยก good / quarantine + เหตุผล
- 3 รัน transform — สร้าง is_default · profit · fico_avg
- 4 ตรวจสอบจำนวนแถว good / quarantine ว่าตรงไหม



เสร็จแล้วได้: DataFrame สะอาด + คอลัมน์ธุรกิจ พร้อมขึ้น star schema



โหลดเข้า MSSQL — จบ ETL

Notebook 03



Database

de_loan_dw



Login (ร่วมกัน)

deadmin



ชื่อตาราง

<TEAM_ID>_fact_loan



Reconcile

row + sum ตรงกัน



ทุกคนใช้ deadmin เหมือนกัน — กันชนด้วย prefix ชื่อตาราง (TEAM_ID) → ไม่ต้องสร้าง schema รายทีม



LAB 3 • ลงมือทำ



25 นาที

โหลด Star Schema เข้า MSSQL

เปิด: [notebooks/03_star_schema_load](#)



[GitHub repo](#)

- 1 สร้าง dimensions + fact จากข้อมูลที่ transform แล้ว
- 2 เขียนลง de_loan_dw → ตาราง <TEAM_ID>_*
- 3 รัน reconcile — row count + ยอดรวมต้องตรง
- 4 เปิด Power BI Desktop ค้างไว้ ใช้ต่อช่วงบ่าย



เสร็จแล้วได้: fact_loan + 7 dimensions อยู่ใน MSSQL — จบกระบวนการ ETL



AFTERNOON SESSION

บ่าย — Power BI Dashboard

ต่อ MSSQL → สร้าง model + DAX → dashboard เล่าเรื่อง



ติดตั้ง Power BI Desktop (Windows)

ฟรี · ใช้ได้เฉพาะ Windows — เลือกติดตั้งได้ 2 ทาง

บาย · เตรียม

1

Microsoft Store

แนะนำ

- เปิด Microsoft Store
- ค้นหา "Power BI Desktop"
- กด Get / Install
- อัปเดตอัตโนมัติ

2

ดาวน์โหลด Installer

- [Microsoft Power BI Desktop](#)
- Download → ได้ไฟล์ .exe
- รันไฟล์ → Next → Install
- เหมาะกับเครื่องที่ปิด Store

⚠ **Mac / Linux:** ไม่มี Power BI Desktop — ใช้ **Power BI Service (เว็บ)** หรือรันผ่าน Windows VM



Power BI: Connect → Model → DAX

บ่าย

1 Connect

Get Data → SQL Server
mssql.minddatatech.com / de_loan_dw
เลือกตาราง <TEAM_ID>_*

2 Model

เชื่อม relationships
fact → dim (star)
mark dim_date เป็น date table

3 DAX

Default Rate %
Total Profit, Total Funded
Avg Int Rate

ตัวอย่าง **DAX**: $\text{Default Rate \%} = \text{DIVIDE}(\text{SUM(is_default)}, \text{COUNTROWS(fact_loan)}) * 100$



 LAB 4 • ลงมือทำ

 **45 นาที**

ติดตั้ง Power BI + ต่อ MSSQL

เปิด: **Power BI Desktop** → **SQL Server**

 [GitHub repo](#)

- 1 ติดตั้ง Power BI Desktop (Store หรือ .exe)
- 2 Get Data → SQL Server → mssql.minddatatech.com / de_loan_dw
- 3 เลือกตาราง <TEAM_ID>_* ของทีมเรา
- 4 Model view: เชื่อม fact → dim + เพิ่ม DAX measures



เสร็จแล้วได้: model แบบ star + measures (Default Rate %, ROI %) พร้อมใช้



Loan Analytics Dashboard — Layout

บ้าย · ผลลัพธ์

Total Funded

00.0

Total Loans

00.0

Default Rate %

00.0


Avg Int Rate

00.0

Total Profit

00.0

Default Rate % vs Int Rate · by Grade




Total Funded · by Month



Total Profit · by Purpose



Default Rate % · by State





LAB 5 • STEP 0



5 นาที

ตรวจสอบความพร้อมก่อนเริ่ม

เปิด: [powerbi/LAB5.md](#) — STEP 0



[GitHub repo](#)

- 1 โหลด 8 ตาราง: fact_loan + 7 dim → rename ตัด teamXX_ ออก
- 2 Relationships ครบ 7 เส้น fact → dim (เกิน = ลบ auto-detect)
- 3 ไม่ต้องใช้ quarantine_loan / measures.dax — เดี่ยวเขียน DAX เอง
- 4 ribbon View → ☒ Gridlines ☒ Snap to grid (Page view = Fit to page อยู่แล้ว)



พร้อมแล้ว — ถัดไป: สร้าง DAX measures 5 ตัวให้ KPI cards



DAX Measures สำหรับ KPI Cards

ป้าย · DAX

measure 1 ตัว = KPI 1 ค่า — สร้างที่ **Modeling** → **New measure** (ตาราง **fact_loan**)

นับ & รวมยอด

Total Loans · Total Funded

เฉลี่ย & กำไร

Avg Int Rate · Total Profit

อัตราเบี้ยหนี้

Default Rate % (DIVIDE กันหารศูนย์)

```
Total Loans = COUNTROWS(fact_loan)
```

```
Total Funded = SUM(fact_loan[funded_amnt])
```

```
Avg Int Rate = AVERAGE(fact_loan[int_rate])
```

```
Total Profit = SUM(fact_loan[profit])
```

```
Default Rate % =  
    DIVIDE(SUM(fact_loan[is_default]),  
           COUNTROWS(fact_loan), 0)
```




 LAB 5 · A1

 5 นาที

KPI Cards — 5 ค่าในการ์ดเดียว

เปิด: [powerbi/LAB5.md](#) — A1

 [GitHub repo](#)

- 1 Visualizations → Card (new) → คลิกวางบน canvas
- 2 Data pane → ดึง measures ทั้ง 5 → ลงช่อง Value ให้เอง
- 3 layout จัดให้เท่ากันอัตโนมัติ — ลากการ์ดยาวเต็มหน้าได้
- 4 Format: Callout value · Label · ลากสลับลำดับใน Value well



เสร็จแล้วได้: แกว KPI 5 ค่า ในการ์ดเดียว — Loans · Funded · Int Rate · Profit · Default %



 LAB 5 · A2

 10 นาที

Combo: Default % vs Int Rate

เปิด: [powerbi/LAB5.md](#) — A2

 [GitHub repo](#)

- 1 Visualizations → Line and clustered column chart
- 2 X: dim_grade[grade] · Column y: Default Rate % · Line y: Avg Int Rate
- 3 เรียงเกรด: ... → Sort axis → grade → Ascending (A→G)

 **เสร็จแล้วได้:** กราฟตอบคำถาม — ตั้งราคาตามความเสี่ยงถูกไหม



 LAB 5 · A3 + A4

 16 นาที

Line รายเดือน + Bar by Purpose

เปิด: [powerbi/LAB5.md](#) – A3 · A4

 [GitHub repo](#)

- 1 Line chart: X = dim_date[year_month] · Y = Total Funded
- 2 Sort ตามเวลา (Ascending) + เปิด Markers ให้อ่านง่าย
- 3 คลิกที่ว่าง → Visualizations → Clustered bar chart (แบ่งแนวนอน)
- 4 Y: dim_purpose[purpose] · X: Total Profit → Sort มาก→น้อย = กำไร/ขาดทุน

 **เสร็จแล้วได้:** แนวโน้มยอดปล่อยกู้รายเดือน + กำไรรายวัตถุประสงค์



LAB 5 · A5

Map ราชรัฐ

เปิด: [powerbi/LAB5.md](#) — A5

 8 นาที

 [GitHub repo](#)

- 1 ตั้งก่อน: dim_geography[addr_state] → Data category = State or Province
- 2 Filled map: Location = dim_geography[addr_state] · Tooltips = Default Rate %
- 3 ผูกสี: Fill colors → ปุ่ม fx → Gradient → field = Default Rate %
- 4 เนด 3 จุด: #FFEDA0 → #FD8D3C → #BD0026 (เหลืองอ่อน→ส้ม→แดงเข้ม)



เสร็จแล้วได้: หน้า Analytics ครบ — การ์ด KPI 5 ค่า + 4 กราฟ



สิ่งที่คุณทำได้หลังวันนี้

สร้าง pipeline จริง CSV → Power BI

- ✓ เขียน Python ETL: clean / validate / quarantine / transform
- ✓ ออกแบบ star schema → โหลดเข้า MSSQL (de_loan_dw)
- ✓ ต่อ Power BI → สร้าง dashboard Loan Analytics

Next steps: dbt · Apache Airflow · Cloud DW (BigQuery/Synapse) · Power BI Advanced · CI/CD

ขอบคุณ — Q & A

 [amornpan/advanced-de-applied-analytics](https://github.com/amornpan/advanced-de-applied-analytics)